

# Estimación de Parámetros Físicos en Supernovas Tipo Ia mediante Redes Neuronales Informadas por la Física (PINNs) Inversas

Giuliana Barbieri  
Licenciatura en Ciencias de Datos  
Universidad de Buenos Aires

Junio 2026

## Índice

|                                                                                                        |          |
|--------------------------------------------------------------------------------------------------------|----------|
| <b>1. Introducción</b>                                                                                 | <b>3</b> |
| 1.1. Las Supernovas Tipo Ia como velas estándar                                                        | 3        |
| 1.2. El problema observacional                                                                         | 3        |
| 1.3. El límite de los métodos tradicionales                                                            | 4        |
| 1.4. Nuestra propuesta                                                                                 | 4        |
| <b>2. Física de las Curvas de Luz de Supernovas Tipo Ia</b>                                            | <b>5</b> |
| 2.1. La Ecuación de Arnett                                                                             | 5        |
| 2.2. El decaimiento radiactivo: $\text{Ni}^{56} \rightarrow \text{Co}^{56} \rightarrow \text{Fe}^{56}$ | 5        |
| 2.3. El rol de la opacidad en la literatura astrofísica                                                | 6        |
| 2.4. La relación de Phillips y la masa de Níquel de referencia                                         | 6        |
| <b>3. Métodos</b>                                                                                      | <b>6</b> |
| 3.1. Datos y preprocesamiento                                                                          | 6        |
| 3.1.1. Objetos analizados                                                                              | 6        |
| 3.1.2. Conversión de magnitud a luminosidad                                                            | 7        |
| 3.1.3. Normalización                                                                                   | 7        |
| 3.2. Arquitectura de la PINN Inversa                                                                   | 7        |
| 3.2.1. Dos redes neuronales acopladas                                                                  | 7        |
| 3.2.2. Restricción fuerte (Hard PINN) para la condición inicial                                        | 8        |
| 3.2.3. <code>ComponentArray</code> : unificación de parámetros                                         | 8        |
| 3.3. Función de pérdida                                                                                | 9        |
| 3.3.1. Pérdida de datos — $\chi^2$                                                                     | 9        |
| 3.3.2. Pérdida física — Residuo de la EDO                                                              | 9        |
| 3.4. Entrenamiento en dos etapas                                                                       | 9        |
| 3.5. Estrategias de muestreo                                                                           | 9        |
| 3.5.1. Importance Sampling                                                                             | 9        |
| 3.5.2. Entrenamiento Causal [15]                                                                       | 10       |

|                                                                                      |           |
|--------------------------------------------------------------------------------------|-----------|
| 3.6. Optimización . . . . .                                                          | 10        |
| <b>4. Resultados</b>                                                                 | <b>10</b> |
| 4.1. Estimación de parámetros físicos . . . . .                                      | 10        |
| 4.1.1. Masa de Níquel ( $M_{\text{Ni0}}$ ) . . . . .                                 | 10        |
| 4.1.2. Tiempo de explosión ( $t_0$ ) y Rise Time . . . . .                           | 11        |
| 4.1.3. Opacidad dinámica ( $\bar{\kappa}$ ) — Una validación independiente . . . . . | 11        |
| 4.2. Experimento de baches: PINN vs Gaussian Process . . . . .                       | 12        |
| <b>5. Discusión y Conclusiones</b>                                                   | <b>13</b> |
| 5.1. Logros principales . . . . .                                                    | 13        |
| 5.2. Limitaciones y experimentos fallidos . . . . .                                  | 13        |
| 5.2.1. Inconsistencia bolométrica . . . . .                                          | 13        |
| 5.2.2. Cálculo analítico de Arnett (retirado) . . . . .                              | 14        |
| 5.2.3. Experimento de normalización común ( $L_{\text{ref}}$ ) . . . . .             | 14        |
| 5.3. Trabajo futuro . . . . .                                                        | 14        |
| <b>6. Agradecimientos</b>                                                            | <b>14</b> |
| <b>7. Datos y Software</b>                                                           | <b>14</b> |

## Resumen

Las Supernovas Tipo Ia (SNIa) son las *velas estándar* de la cosmología moderna, pero sus curvas de luz fotométricas presentan muestreos irregulares y huecos observacionales que dificultan su caracterización. Los métodos tradicionales —como los Procesos Gaussianos (GP)— interpolan sin incorporar la física de la explosión, y no estiman parámetros astrofísicos como la masa de Níquel ( $M_{\text{Ni0}}$ ) o el tiempo de explosión ( $t_0$ ). En este trabajo implementamos una Red Neuronal Informada por la Física (PINN) inversa que, a partir de datos fotométricos del Zwicky Transient Facility (ZTF), reconstruye la curva de luz continua, estima  $M_{\text{Ni0}}$ ,  $t_0$  y la opacidad dinámica  $\kappa(t)$  simultáneamente, utilizando la ecuación de Arnett (1982) como restricción termodinámica. La arquitectura emplea dos redes neuronales acopladas, una restricción para forzar  $F(t_0) = 0$ , y entrenamiento en dos etapas con estrategias de importance sampling y entrenamiento causal. Sobre tres objetos ZTF confirmados por el Bright Transient Survey de Caltech, la PINN estima  $M_{\text{Ni0}}$  dentro del rango de literatura en 2 de 3 objetos sin conocer la relación de Phillips. La red  $\beta_2$  aprende una opacidad promedio, coincidiendo con el valor canónico de la literatura, y descubre autónomamente una correlación predicha por Woosley et al. (2008). Un experimento controlado de relleno de huecos muestra que la PINN supera al GP en el escenario realista del ZTF. Se discuten las limitaciones del modelo, incluyendo una inconsistencia hallada.

## 1. Introducción

### 1.1. Las Supernovas Tipo Ia como velas estándar


Las Supernovas Tipo Ia (SNIa) son explosiones termonucleares de enanas blancas en sistemas binarios. Constituyen una de las herramientas más poderosas de la cosmología moderna: su brillo máximo calibrado permitió descubrir la expansión acelerada del universo, un hallazgo galardonado con el Premio Nobel de Física en 2011 [13, 9]. La razón de su utilidad cosmológica es que las SNIa actúan como *velas estándar*: una vez corregida la relación entre el ancho de la curva de luz y el brillo máximo (la relación de Phillips; [10]), su magnitud absoluta de pico es notablemente uniforme.

Más allá de su valor cosmológico, cada curva de luz de una SNIa contiene información sobre los parámetros físicos de la explosión: la masa inicial de Níquel-56 sintetizado ( $M_{\text{Ni0}}$ ), el tiempo transcurrido desde la explosión hasta las primeras observaciones ( $t_0$ ), y la opacidad del material eyectado ( $\kappa$ ). Estos parámetros son indicadores directos de la física de la explosión termonuclear, pero tradicionalmente requieren pipelines de modelado separados y costosos para ser estimados.


### 1.2. El problema observacional

El Zwicky Transient Facility (ZTF; [2]) escanea el cielo nocturno y genera alertas fotométricas de objetos transientes. Cada detección es procesada por brokers como ALeRCE [4] y almacenada como una fila en un archivo CSV con campos como la fecha juliana modificada (mjd), la magnitud PSF (magpsf), su incertidumbre (sigmapsf) y el filtro utilizado (fid:  $g = 1$ ,  $r = 2$ ).

Sin embargo, las curvas de luz resultantes presentan **muestreos irregulares y huecos observacionales** (en la Figura 1 se muestran dos ejemplos de datos obtenidos con



(a) Ejemplo de buenos datos observados: 168 pts



(b) Ejemplo de pocos datos observados: 25 pts

Figura 1: Tipos de datos que podemos encontrar en el dataset de ZTF. El objeto (a) fue uno de los 3 objetos con los que se entrenó la PINN, por ser uno de los eventos con más observaciones y menor cantidad de huecos. El caso (b) es un ejemplo de evento con muy pocos datos. Lo mas frecuente es tener datos como (b).

ZTF) debido a limitaciones climáticas, rotación entre telescopios, prioridades de observación y latencia en la detección del transiente. Estos huecos pueden extenderse por varios días o incluso semanas consecutivas, dificultando la caracterización precisa de la curva de luz.

### 1.3. El límite de los métodos tradicionales

El enfoque estándar para interpolar curvas de luz con datos faltantes es el **Gaussian Process (GP)** con un kernel RBF (Radial Basis Function). El GP ajusta una función suave a los puntos observados optimizando la log-marginal-likelihood del kernel [12]. Si bien el GP produce una interpolación suave, presenta dos limitaciones fundamentales para nuestro problema:

1. **Ignora la física de la explosión.** El kernel RBF no incorpora ningún conocimiento sobre el decaimiento radiactivo del Níquel-56 o la ecuación de conservación de energía que gobierna la evolución de la curva de luz. En un hueco de 8 días sin datos, el GP tiende a aplanarse hacia la media del proceso, mientras que la física dicta que la curva de luz debe seguir una forma dictada por la desintegración radiactiva.
2. **No estima parámetros físicos.** El GP solo interpola. Para obtener  $M_{\text{Ni0}}$  con métodos tradicionales es necesario un pipeline completamente separado: (a) ajustar plantillas de curvas de luz con **sncosmo**, (b) obtener la magnitud absoluta en banda B ( $M_B$ ) mediante la relación de Phillips [10], y (c) convertir  $M_B$  a masa de Níquel usando la relación de escala de Stritzinger & Leibundgut [14].

### 1.4. Nuestra propuesta

Este trabajo propone una **Red Neuronal Informada por la Física (PINN; [11])** que, a partir de los mismos datos fotométricos de ZTF, realiza **simultáneamente** tres tareas que tradicionalmente requieren pipelines separados:

1. **Reconstruir** la curva de luz continua  $F(t)$  en todo el dominio temporal, incluso en intervalos sin datos observacionales.

2. **Estimar** la masa inicial de Níquel-56 ( $M_{\text{Ni0}}$ ), el tiempo de explosión ( $t_0$ ) y la opacidad dinámica del eyecta ( $\kappa(t)$ ).
3. **Cumplir** la ecuación de Arnett (1982) como restricción termodinámica, garantizando que la solución interpolada respete el balance energético radiactivo.

La arquitectura utiliza **dos redes neuronales acopladas** ( $\beta_1$  y  $\beta_2$ ), una **restricción fuerte** (Hard PINN) para forzar la condición inicial  $F(t_0) = 0$ , y un entrenamiento en **dos etapas** con estrategias de muestreo de puntos de colocación y entrenamiento causal. El modelo se implementó en Julia utilizando el ecosistema Lux.jl + Zygote + Optimisers.jl.

El desempeño de la PINN se evalúa sobre tres objetos ZTF confirmados espectroscópicamente como SNIa por el Bright Transient Survey (BTS) de Caltech, comparando sus estimaciones de  $M_{\text{Ni0}}$  contra los valores de literatura derivados de la relación de Phillips. Adicionalmente, se realiza un experimento controlado de relleno de baches comparando la PINN contra un GP en seis escenarios de datos faltantes.

## 2. Física de las Curvas de Luz de Supernovas Tipo Ia

### 2.1. La Ecuación de Arnett

La evolución temporal de la luminosidad de una SNIa está gobernada por la **ecuación diferencial ordinaria de Arnett** [1], que describe el balance entre la energía inyectada por decaimiento radiactivo y la energía que escapa del eyecta en expansión:

$$\frac{dF}{dt} = \kappa(t) \cdot \left( \frac{\varepsilon(t)}{L_{\text{máx}}} - F(t) \right) \quad (1)$$

donde:

- $F(t) = L(t)/L_{\text{máx}}$  es el flujo normalizado (adimensional), con  $L(t)$  la luminosidad en erg/s y  $L_{\text{máx}}$  la luminosidad máxima observada.
- $\kappa(t)$  es la **opacidad efectiva** del material eyectado (en 1/día). Físicamente,  $\kappa$  modula qué tan rápido la energía radiactiva se convierte en radiación observable.
- $\varepsilon(t)$  es la **tasa de producción de energía radiactiva** (en erg/s), el término fuente de la ecuación.

La ecuación (1) tiene una interpretación física directa: el cambio en el brillo ( $dF/dt$ ) está gobernado por la competencia entre la energía inyectada ( $\varepsilon(t)/L_{\text{máx}}$ , que tiende a aumentar  $F$ ) y la energía que escapa ( $F(t)$ , que tiende a disminuir  $F$ ). La opacidad  $\kappa(t)$  controla la velocidad de este intercambio.

### 2.2. El decaimiento radiactivo: $\text{Ni}^{56} \rightarrow \text{Co}^{56} \rightarrow \text{Fe}^{56}$

La fuente de energía que alimenta la curva de luz es la cadena de desintegración radiactiva Níquel-56  $\rightarrow$  Cobalto-56  $\rightarrow$  Hierro-56. La tasa de producción energética total es:

$$\varepsilon(t) = \varepsilon_{\text{Ni}}(t) + \varepsilon_{\text{Co}}(t) \quad (2)$$

$$\varepsilon_{\text{Ni}}(t) = \epsilon_{\text{Ni},0} \cdot M_{\text{Ni0}} \cdot e^{-t/\tau_{\text{Ni}}} \quad (3)$$

$$\varepsilon_{\text{Co}}(t) = \epsilon_{\text{Co},0} \cdot M_{\text{Ni0}} \cdot \frac{e^{-t/\tau_{\text{Co}}} - e^{-t/\tau_{\text{Ni}}}}{1 - \tau_{\text{Ni}}/\tau_{\text{Co}}} \quad (4)$$

donde las constantes físicas son:

- $\tau_{\text{Ni}} = 8.44$  días,  $\tau_{\text{Co}} = 111.26$  días: vidas medias de los isótopos.
- $\epsilon_{\text{Ni},0} = 3.90 \times 10^{10}$  erg/s/g,  $\epsilon_{\text{Co},0} = 6.78 \times 10^9$  erg/s/g: tasas de producción energética por gramo.
- La conversión a  $M_{\odot}$  se realiza multiplicando por  $M_{\odot} = 1.989 \times 10^{33}$  g.

La ecuación (4) refleja que el  $\text{Co}^{56}$  se produce a partir del decaimiento del  $\text{Ni}^{56}$ : su contribución crece inicialmente para luego decaer con su propia vida media. El factor  $(1 - \tau_{\text{Ni}}/\tau_{\text{Co}})$  en el denominador normaliza esta producción secuencial.

## 2.3. El rol de la opacidad en la literatura astrofísica

En la práctica estándar de modelado de supernovas, la opacidad  $\kappa$  se trata como una **constante fija**. El consenso en la literatura es [16]:

$$\kappa_{\text{canónico}} = 0.10 \text{ cm}^2\text{g}^{-1} \quad (5)$$

La razón de fijar  $\kappa$  es matemática: si varía libremente, la EDO se vuelve difícil de resolver de forma cerrada y el modelo degenera.

Como se verá en la Sección 4, nuestra PINN aprende  $\kappa(t)$  de forma dinámica y el valor promedio que emerge del entrenamiento coincide con este valor canónico.

## 2.4. La relación de Phillips y la masa de Níquel de referencia

El estándar en la comunidad para estimar la masa de Níquel de una SNIa es la **relación de Phillips** [10], que correlaciona la magnitud absoluta en banda B ( $M_B$ ) con la tasa de declinación. La masa de Níquel se estima [14, 3]:

$$\log_{10}(M_{\text{Ni}}/M_{\odot}) \approx -0.4 \cdot M_B - 7.95 \quad (6)$$

En este trabajo, los  $M_B$  provienen del **ZTF Bright Transient Survey (BTS)** de Caltech, disponibles en el ZTF Sample Explorer<sup>1</sup>. El BTS clasifica espectroscópicamente cada objeto y ajusta su fotometría con **sncosmo**.

Cuadro 1: Valores de referencia:  $M_B$  del BTS y masa de Níquel estimada por Phillips.

| Objeto       | $M_B$ (pico) | Tipo BTS        | $M_{\text{Ni}}$ estimado ( $M_{\odot}$ ) |
|--------------|--------------|-----------------|------------------------------------------|
| ZTF25aavdmzf | −19.3        | Ia normal       | 0.52–0.58                                |
| ZTF25aaxjntk | −19.1        | Ia transicional | 0.35–0.42                                |
| ZTF25aaxeojh | −19.3        | Ia normal       | 0.80–1.30                                |

Es fundamental destacar que **la PINN no conoce la relación de Phillips, la magnitud  $M_B$  ni la fórmula (6)**. Estima  $M_{\text{Ni}0}$  exclusivamente a partir del CSV y la EDO de Arnett.

## 3. Métodos

### 3.1. Datos y preprocesamiento

#### 3.1.1. Objetos analizados

Se analizaron tres supernovas Tipo Ia confirmadas por el BTS de Caltech:

<sup>1</sup><https://sites.astro.caltech.edu/ztf/bts/explorer.php>

Cuadro 2: Objetos ZTF analizados.

| Objeto       | Redshift ( $z$ ) | Distancia (Mpc) | Puntos ZTF | Tipo (BTS)      |
|--------------|------------------|-----------------|------------|-----------------|
| ZTF25aavdmzf | 0.0407           | 174.3           | 168        | Ia normal       |
| ZTF25aaxjntk | 0.01633          | 69.9            | 74         | Ia transicional |
| ZTF25aaxeojh | 0.049            | 209.9           | 148        | Ia normal       |

Los datos provienen del broker ALerCE, que procesa las alertas ZTF en bandas  $g$  ( $\text{fid}=1$ ) y  $r$  ( $\text{fid}=2$ ). Se filtran detecciones marcadas como *dubious* o con incertidumbre no disponible.

### 3.1.2. Conversión de magnitud a luminosidad

Las magnitudes aparentes  $\text{magpsf}$  deben convertirse a luminosidades en erg/s. El proceso consta de tres pasos:

**Paso 1 — Distancia cosmológica.** Vía Ley de Hubble ( $H_0 = 70$  km/s/Mpc,  $c = 299\,792$  km/s):

$$D = \frac{c \cdot z}{H_0} \quad (7)$$

**Paso 2 — Magnitud absoluta.** Corrección por distancia ( $D$  en Mpc):

$$M = m_{\text{psf}} - 5 \log_{10}(D) - 25 \quad (8)$$

**Paso 3 — Luminosidad.** Conversión de magnitud absoluta a erg/s:

$$L = 3.0128 \times 10^{35} \cdot 10^{-0.4M} \quad (9)$$

El factor  $3.0128 \times 10^{35}$  es la luminosidad de una fuente con  $M = 0$  en el sistema adoptado.

### 3.1.3. Normalización

Las luminosidades se normalizan por el máximo de cada supernova y los tiempos por el tiempo máximo de observación:

$$F(t) = \frac{L(t)}{L_{\text{máx}}}, \quad t_{\text{norm}} = \frac{t}{T_{\text{máx}}} \quad (10)$$


La incertidumbre se propaga como  $\sigma_F = F \cdot \ln(10) \cdot 0.4 \cdot \sigma_{\text{mag}}$ .

## 3.2. Arquitectura de la PINN Inversa

### 3.2.1. Dos redes neuronales acopladas

El modelo utiliza **dos redes neuronales acopladas** que se entrenan conjuntamente:

Figura 2: Arquitectura dual de la PINN inversa:  $\beta_1$  (izquierda) reconstruye el flujo  $F(t)$ ,  $\beta_2$  (derecha) aprende la opacidad  $\kappa(t)$ . Ambas comparten el vector de parámetros  $\theta$ .



$\beta_2$  utiliza activación Softplus en la capa de salida para garantizar  $\kappa(t) \geq 0$ , físicamente necesario.

### 3.2.2. Restricción fuerte (Hard PINN) para la condición inicial

La condición física esencial es  $F(t_0) = 0$ . Siguiendo la metodología de *Hard PINNs* [7], imponemos esta restricción en la arquitectura mediante reparametrización (sin penalizarla en la pérdida):

$$F_{\text{física}}(t) = \phi(t - t_0) \cdot \text{NN}_{\beta_1}(t), \quad \phi(\tau) = \max(0, \tau) \quad (11)$$

$\phi$  —LeakyReLU— garantiza  $F_{\text{física}}(t) = 0$  para  $t \leq t_0$ . Además,  $t_0$  queda como **parámetro aprendible**: la red descubre el día de explosión sin marcadores externos.

### 3.2.3. ComponentArray: unificación de parámetros

Todos los parámetros se agrupan en una única estructura:

$$\theta = [\mathbf{W}_1, \mathbf{b}_1, \mathbf{W}_2, \mathbf{b}_2, M_{\text{Ni0}}, t_0] \quad (12)$$



Esto permite que el motor de diferenciación automática **Zygote** [5] calcule gradientes simultáneamente sobre pesos de redes y parámetros físicos escalares.

### 3.3. Función de pérdida

La función de costo sigue la estructura de una PINN Lagrangiana:

$$\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{data}} + \lambda \cdot \mathcal{L}_{\text{phys}} \quad (13)$$

#### 3.3.1. Pérdida de datos — $\chi^2$

La pérdida empírica es un estadístico **chi-cuadrado** ( $\chi^2$ ), no un MSE estándar. Al dividir por  $\sigma$ , los puntos confiables pesan más:

$$\mathcal{L}_{\text{data}} = \frac{1}{N} \sum_{i=1}^N \left( \frac{F_{\text{pred}}(t_i) - F_{\text{obs},i}}{\sigma_{\text{obs},i}} \right)^2 \quad (14)$$

#### 3.3.2. Pérdida física — Residuo de la EDO

Penaliza la violación de la ecuación de Arnett en  $M$  puntos de colocación  $\{t_j\}_{j=1}^M$ :

$$\mathcal{L}_{\text{phys}} = \frac{1}{M} \sum_{j=1}^M \left[ \frac{dF}{dt}(t_j) - \kappa(t_j) \cdot \left( \frac{\varepsilon(t_j)}{L_{\text{máx}}} - F(t_j) \right) \right]^2 \quad (15)$$

La derivada  $dF/dt$  se calcula por diferencias finitas centradas ( $h = 0.001$  en  $t_{\text{norm}}$ ):

$$\frac{dF}{dt}(t) \approx \frac{F(t+h) - F(t-h)}{2h \cdot T_{\text{máx}}} \quad (16)$$

Este esquema es diferenciable por Zygote, propagando gradientes a través de la derivada sin necesidad de una segunda red.

### 3.4. Entrenamiento en dos etapas

**Etapas 1 — Ajuste a los datos ( $\lambda = 0$ , 2000 épocas).** Solo  $\beta_1$  entrena para ajustar la curva de luz.  $\beta_2$  no recibe gradiente y  $t_0$  se congela. Cada 100 épocas se regenera la grilla de colocación mediante una distribución híbrida exponencial+uniforme:

$$t_{\text{physics}} = \frac{e^{2u} - 1}{e^2 - 1}, \quad u \sim \mathcal{U}(0, 1) \quad (17)$$

**Etapas 2 — Física activa ( $\lambda = 10^{-5}$ , 3000 épocas).** Ambas redes entrenan.  $\beta_1$  se afina,  $\beta_2$  aprende  $\kappa(t)$  desde cero, y  $M_{\text{Ni0}}$ ,  $t_0$  convergen guiados por el residuo de la EDO.

### 3.5. Estrategias de muestreo

#### 3.5.1. Importance Sampling

En la Etapa 2, los puntos de colocación se reubican dinámicamente según los residuos físicos:

$$P(x_i^{k+1}) \propto \exp(\alpha \cdot |\text{Residuo}_i|), \quad \alpha = 2.0 \quad (18)$$

### 3.5.2. Entrenamiento Causal [15]

Las PINNs en sistemas dinámicos tienden a “hacer trampa”: ajustan bien tiempos tardíos (fáciles) descuidando los tempranos (críticos). El entrenamiento causal fuerza el orden cronológico:

$$W(t_i) = \exp \left( -\varepsilon_c \cdot \sum_{k=1}^{i-1} \text{Residuo}^2(t_k) \right), \quad \varepsilon_c = 0.3 \quad (19)$$

Si los residuos tempranos son altos,  $W(t_i) \approx 0$  para tiempos posteriores: el gradiente se concentra en resolver primero la explosión. Solo cuando los tiempos tempranos mejoran, los tardíos se “desbloquean”.

## 3.6. Optimización

El optimizador **Adam** [6] se utiliza con tasa de aprendizaje  $5 \times 10^{-4}$ . El flujo en cada época es:

1. *Forward*: `calculate_loss(ps_total)` evalúa las redes y computa  $\mathcal{L}_{\text{total}}$ .
2. *Backward*: `Zygote.withgradient` aplica diferenciación automática reversa (back-propagation).
3. *Actualización*: `Optimisers.update` aplica Adam para actualizar cada parámetro.

## 4. Resultados

### 4.1. Estimación de parámetros físicos

La Tabla 3 presenta los resultados principales con entrenamiento causal ( $\varepsilon_c = 0.3$ ).

Cuadro 3: Parámetros físicos estimados por la PINN inversa.

| Objeto       | $M_{\text{Ni0}}$ PINN<br>( $M_{\odot}$ ) | $M_{\text{Ni0}}$ Literatura<br>( $M_{\odot}$ ) | Rise Time<br>(días) | $t_0$ final<br>(días) | $\bar{\kappa}$<br>(días $^{-1}$ ) |
|--------------|------------------------------------------|------------------------------------------------|---------------------|-----------------------|-----------------------------------|
| ZTF25aavdmzf | <b>0.573</b>                             | 0.52–0.58                                      | 17.7                | 3.6                   | 0.103                             |
| ZTF25aaxjntk | <b>0.376</b>                             | 0.35–0.42                                      | 20.8                | 7.7                   | 0.098                             |
| ZTF25aaxeojh | 0.578                                    | 0.80–1.30                                      | 16.7                | 2.7                   | 0.107                             |

#### 4.1.1. Masa de Níquel ( $M_{\text{Ni0}}$ )

La PINN estima  $M_{\text{Ni0}}$  dentro del rango de literatura en **2 de 3 objetos**. Desconociendo la relación de Phillips,  $M_B$  y la fórmula (6).

- **ZTF25aavdmzf**: 0.573  $M_{\odot}$ , en rango (0.52–0.58). Sin entrenamiento causal: 0.383  $M_{\odot}$  (+50 % de mejora).
- **ZTF25aaxjntk**: 0.376  $M_{\odot}$ , en rango (0.35–0.42).
- **ZTF25aaxeojh**: 0.578  $M_{\odot}$ , por debajo del rango (0.80–1.30). La discrepancia se discute en la Sección 5.




Figura 3: Opacidad estimada en función del tiempo. Presenta un comportamiento físicamente coherente: si observamos la curva de luz de la explosión, se puede apreciar que al principio gana luminosidad (la opacidad comienza con un valor positivo), alcanza un máximo que ronda el día 18 del evento (el cual coincide con el mínimo de la opacidad) y finalmente el brillo decae (luego del mínimo, la opacidad vuelve a crecer).

#### 4.1.2. Tiempo de explosión ( $t_0$ ) y Rise Time

La PINN demuestra **estabilidad notable** en  $t_0$ . Partiendo de valores iniciales distintos ( $-0.05, 0.0, +0.025$  en  $t_{\text{norm}}$ ), converge al mismo día de explosión para cada objeto. El *rise time* resultante (16.7–20.8 días) coincide con el valor canónico de la literatura ( $\sim 17.8$  días).  $t_0$  es un parámetro enteramente aprendible: el modelo **descubre** cuándo ocurrió la explosión sin marcadores externos.

**Cuenca de atracción espuria ( $\sim 24$ – $25$  días).** Se identificó una segunda cuenca de atracción durante la exploración de hiperparámetros **sin entrenamiento causal**. Con  $t_{0,\text{init}} = -0.1$  (equivalente a  $\sim 10$  días antes del primer dato) y 2000 épocas de Etapa 1, el modelo salta a un mínimo local con rise time de 24.4–25.5 días en los tres objetos —el doble del canónico. Con Etapa 1 más corta (1000 épocas) el modelo se mantiene en la cuenca correcta ( $\sim 17$ – $18$  días).

#### 4.1.3. Opacidad dinámica ( $\bar{\kappa}$ ) — Una validación independiente

La Tabla 4 muestra los valores de opacidad y su correlación con  $M_{\text{Ni0}}$ .

Cuadro 4: Correlación  $M_{\text{Ni0}} \uparrow \rightarrow \bar{\kappa} \uparrow$  aprendida por la PINN.

| Objeto       | $M_{\text{Ni0}}$ PINN ( $M_{\odot}$ ) | $\bar{\kappa}$ (días $^{-1}$ ) |
|--------------|---------------------------------------|--------------------------------|
| ZTF25aaxjntk | 0.376                                 | 0.098                          |
| ZTF25aavdmzf | 0.573                                 | 0.103                          |
| ZTF25aaxeojh | 0.578                                 | 0.107                          |




Figura 4: Comparativa de la reconstrucción fotométrica obtenida mediante la arquitectura PINN dual inversa (línea sólida) frente al ajuste puramente estadístico de Procesos Gaussianos (línea punteada) para el objeto ZTF25aavdmzf.  $t_{\text{norm}}$  es el tiempo normalizado, las equis (x) representan los datos ausentes contra los cuales se calcula el error. Se observa que el ajuste es muy bueno para ambos, pero la PINN resulta levemente superior al preservar la forma física en las zonas sin datos.

Dos observaciones emergen:

1. **Coincidencia con el valor canónico.** La literatura fija  $\kappa = 0.10 \text{ cm}^2 \text{ g}^{-1}$  (5). Nuestra red  $\beta_2$  —inicializada aleatoriamente, sin prior astrofísico— converge a  $\bar{\kappa} \approx 0.10$ .
2. **Correlación  $M_{\text{NiO}} \uparrow \rightarrow \bar{\kappa} \uparrow$ .** Woosley et al. [16] predicen: “ $\kappa$  increases with temperature/ionization, thus models with larger  $M_{\text{Ni}}$  will typically have slightly longer diffusion times.” La red  $\beta_2$  **no fue programada** con esta correlación —la descubrió autónomamente.

## 4.2. Experimento de baches: PINN vs Gaussian Process

Para cuantificar la ventaja en el escenario realista del ZTF, se comparó la reconstrucción de la PINN contra un GP (kernel RBF) sobre ZTF25aavdmzf (168 puntos) en seis escenarios de datos faltantes.

Cuadro 5: Comparación PINN vs GP en seis escenarios. NRMSE = Normalized Root Mean Square Error (porcentaje del rango total).

| Experimento                | $n_{\text{train}}$ | $n_{\text{excl}}$ | NRMSE GP       | NRMSE PINN     | $R^2$ GP     | $R^2$ PINN   | $\Delta M_{\text{NiO}}$ |
|----------------------------|--------------------|-------------------|----------------|----------------|--------------|--------------|-------------------------|
| Random 50 %                | 83                 | 84                | 9.44 %         | <b>9.38 %</b>  | 0.851        | <b>0.853</b> | 0.97 %                  |
| Random 80 %                | 33                 | 135               | <b>10.69 %</b> | 12.16 %        | <b>0.809</b> | 0.753        | 28.27 %                 |
| Gaps $3 \times 8\text{d}$  | 140                | 28                | 11.87 %        | <b>10.94 %</b> | 0.730        | <b>0.771</b> | 3.77 %                  |
| Gaps $2 \times 15\text{d}$ | 95                 | 73                | 9.87 %         | <b>9.78 %</b>  | 0.303        | <b>0.316</b> | 5.49 %                  |
| Combinado                  | 117                | 50                | <b>9.53 %</b>  | 14.33 %        | <b>0.889</b> | 0.749        | 20.55 %                 |
| Extremo                    | 40                 | 127               | <b>11.09 %</b> | 21.21 %        | <b>0.816</b> | 0.327        | 52.80 %                 |

Los resultados:

- **Gaps continuos** ( $3 \times 8d$ ,  $2 \times 15d$ ): La PINN supera levemente al GP. La física de Arnett mantiene la forma de la curva donde el GP se aplana.  $\Delta M_{\text{Ni0}} < 6\%$ .
- **Random 50 %**: Empate técnico.
- **Random 80 % y Combinado**: El GP gana ( $< 50\%$  de datos).
- **Extremo** ( $< 25\%$ ): El GP duplica a la PINN en  $R^2$ .

**Conclusión del experimento:** La PINN tiene un desempeño general muy similar al GP, siendo levemente superior en el escenario realista del ZTF (donde simulamos los huecos continuos prolongados), aunque requiere retener aproximadamente el 50 % de los puntos observacionales para que la física tenga suficiente señal. En conclusión, mientras que los Procesos Gaussianos se podrían usar exclusivamente para interpolar la curva de luz de forma estadística, la PINN otorga la enorme ventaja de resolver simultáneamente la información termonuclear de la supernova.

## 5. Discusión y Conclusiones

### 5.1. Logros principales

1. **Estimación de  $M_{\text{Ni0}}$  en 2 de 3 objetos** dentro del rango de literatura, sin conocer la relación de Phillips ni  $M_B$ .
2. **Estabilidad en  $t_0$** . El rise time canónico ( $\sim 17$ – $18$  días) emerge para todos los objetos.
3. **Validación independiente de  $\kappa$** .  $\beta_2$  aprende  $\bar{\kappa} \approx 0.10$  sin prior, coincidiendo con el valor canónico, y descubre la correlación  $M_{\text{Ni0}} \uparrow \rightarrow \bar{\kappa} \uparrow$  [16].
4. **Innovación Metodológica en SciML (Entrenamiento Causal)**: La incorporación de un esquema de aprendizaje temporal causal —adoptado de la literatura de vanguardia de redes informadas por la física— estabilizó el espacio de pérdida. Su aplicación produjo una mejora neta del  $+50\%$  en la estimación final de  $M_{\text{Ni0}}$  para el objeto ZTF25aavdmzf.

### 5.2. Limitaciones y experimentos fallidos

#### 5.2.1. Inconsistencia bolométrica

La limitación más significativa fue señalada por la **Dra. Melina Bersten** (FCAG-UNLP): la EDO de Arnett es **bolométrica** (energía integrada sobre todas las longitudes de onda), mientras que nuestros datos de ZTF están en dos bandas individuales ( $g$  y  $r$ ). La conversión `mag_to_luminosity` trata cada banda como si contuviera el 100 % de la energía, lo cual no es físicamente correcto.

Consecuencias:

- $L_{\text{máx}}$  proviene de una sola banda, no del pico bolométrico real.
- Evaluar la EDO bolométrica sobre flujo monobanda introduce error sistemático en  $M_{\text{Ni0}}$  y  $\kappa$ .
- Sumar  $g + r$  sobrestima por  $\sim 2$ – $3\times$  (faltan UV e IR).

### 5.2.2. Cálculo analítico de Arnett (retirado)

Inicialmente se incluyó un cálculo analítico de  $M_{\text{Ni0}}$  basado en la fórmula invertida de la EDO de Arnett evaluada en el pico. Este cálculo fue **retirado** porque utiliza  $L_{\text{máx}}$  de una sola banda en lugar del pico bolométrico, invalidando el resultado. La comparación relevante para la comunidad es contra la relación de Phillips, no contra una fórmula de Arnett mal calibrada.

### 5.2.3. Experimento de normalización común ( $L_{\text{ref}}$ )

Se exploró la hipótesis de que la normalización por objeto borraba diferencias de brillo absoluto. Se implementó un  $L_{\text{ref}}$  común (máximo de los tres  $L_{\text{máx}}$ ) para todas las SN. El experimento **no mejoró los resultados**: ZTF25aaxjntk cayó de 0.376 a 0.219  $M_{\odot}$ , y ZTF25aaxeojh de 0.578 a 0.534  $M_{\odot}$ . Esto confirma que el problema no es la normalización, sino la naturaleza per-banda del flujo.

## 5.3. Trabajo futuro

1. **Corrección bolométrica** vía modelos SED de SNIa dependientes de la fase, para estimar la luminosidad bolométrica real.
2. **Extensión a más objetos** del ZTF Bright Transient Survey.
3. **Aplicación a transientes en tiempo real** donde  $t_0$  es desconocido.

## 6. Agradecimientos

La autora agradece al **Dr. Facundo Sapienza** por las clases del curso DM2026 (Universidad de Buenos Aires) que proveyeron el marco teórico y computacional. Las Clases 8 (dualidad Lagrangiana) y 9 (Hard PINNs) fueron particularmente formativas; la Clase 10 (resampleo e importance sampling) informó las estrategias de muestreo.

Un agradecimiento especial a la **Dra. Melina Bersten** (FCAG-UNLP) por señalar la inconsistencia bolométrica, observación que reorientó la discusión de limitaciones y trabajo futuro. Asimismo, agradecemos sus valiosas precisiones sobre la variabilidad intrínseca del *rise time* en las SNIa; su señalamiento de que es físicamente esperable encontrar sutiles desviaciones respecto al valor canónico de 18 días aportó un sólido respaldo conceptual para validar la dispersión natural obtenida en las predicciones de nuestro modelo.

**Declaración de uso de inteligencia artificial.** La autora utilizó **DeepSeek-v4 (Coder)** como asistente de programación para la implementación del código en Julia, depuración, redacción de documentación y discusión de conceptos astrofísicos. Se utilizó **Gemini** (Google) para la generación de prompts destinados a diagramas del póster y la revisión de estilo académico. Todas las ecuaciones, resultados numéricos y conclusiones científicas fueron verificados manualmente por la autora.

## 7. Datos y Software

**Datos.** Los datos fotométricos provienen del Zwicky Transient Facility (ZTF; [2]), procesados por el broker ALeRCE [4]. Las curvas de luz están disponibles públicamente en

el ZTF Sample Explorer<sup>2</sup> de Caltech. Los redshifts y clasificaciones provienen del ZTF Bright Transient Survey (BTS).

**Repositorio:** <https://github.com/giulianabarbieri/SNIa-PINN>

**Software.** El proyecto fue desarrollado en **Julia v1.10** con los paquetes: Lux.jl [8] (redes neuronales), Zygote.jl [5] (diferenciación automática), Optimisers.jl (Adam; [6]), ComponentArrays.jl, CSV.jl, DataFrames.jl, y Plots.jl.

El código fuente completo está disponible en el repositorio público de GitHub mencionado anteriormente.

## Referencias

- [1] Arnett, W. D. (1982). Type I supernovae. I — Analytic solutions for the early part of the light curve. *The Astrophysical Journal*, 253, 785–797.
- [2] Bellm, E. C., et al. (2019). The Zwicky Transient Facility: System overview, performance, and first results. *PASP*, 131(995), 018002.
- [3] Childress, M. J., et al. (2015). Measuring nickel masses in Type Ia supernovae using cobalt emission in nebular phase spectra. *MNRAS*, 454(4), 3816–3842.
- [4] Förster, F., et al. (2021). The Automatic Learning for the Rapid Classification of Events (ALeRCE) alert broker. *The Astronomical Journal*, 161(5), 242.
- [5] Innes, M. (2018). Don’t unroll adjoint: Differentiating SSA-form programs. *arXiv preprint*, arXiv:1810.07951.
- [6] Kingma, D. P., & Ba, J. (2015). Adam: A method for stochastic optimization. *ICLR*.
- [7] Lu, L., Pestourie, R., Yao, W., Wang, Z., Verdugo, F., & Johnson, S. G. (2021). Physics-informed neural networks with hard constraints for inverse design. *SIAM J. Sci. Comput.*, 43(6), B1105–B1132.
- [8] Pal, A. (2023). Lux: Explicit parameterization of deep neural networks in Julia. *GitHub repository*, <https://github.com/LuxDL/Lux.jl>.
- [9] Perlmutter, S., et al. (1999). Measurements of  $\Omega$  and  $\Lambda$  from 42 high-redshift supernovae. *The Astrophysical Journal*, 517(2), 565–586.
- [10] Phillips, M. M. (1993). The absolute magnitudes of Type Ia supernovae. *The Astrophysical Journal*, 413, L105–L108.
- [11] Raissi, M., Perdikaris, P., & Karniadakis, G. E. (2019). Physics-informed neural networks: A deep learning framework for solving forward and inverse problems. *Journal of Computational Physics*, 378, 686–707.
- [12] Rasmussen, C. E., & Williams, C. K. I. (2006). *Gaussian Processes for Machine Learning*. MIT Press.

---

<sup>2</sup><https://sites.astro.caltech.edu/ztf/bts/explorer.php>

- [13] Riess, A. G., et al. (1998). Observational evidence from supernovae for an accelerating universe and a cosmological constant. *The Astronomical Journal*, 116(3), 1009–1038.
- [14] Stritzinger, M., & Leibundgut, B. (2005). Lower limits on the Hubble constant from models of Type Ia supernovae. *Astronomy & Astrophysics*, 431, 423–433.
- [15] Wang, S., Sankaran, S., & Perdikaris, P. (2022). Respecting causality is all you need for training physics-informed neural networks. *CMAME*, 400, 115539.
- [16] Woosley, S. E., Kasen, D., Blinnikov, S., & Sorokina, E. (2008). Type Ia supernova light curves. Draft version, February 5, 2008.